ENCG Settat

École Nationale de Commerce et de Gestion

Peut-on battre la marche aléatoire ?

Prédiction de la hausse ou de la baisse de l'action
Attijariwafa Bank à partir de ses données historiques

Module : Bases de données et Data Science

Projet : F8 – Data Science appliquée à la finance

Année universitaire : 2026–2027

Réalisé par :

Abdelmoughit Moussaid
Hamza Laraki

Novembre 2026

Résumé

Ce travail examine si l'historique des cours de l'action Attijariwafa Bank (ATW), cotée à la Bourse de Casablanca, permet de prédire le sens du rendement du lendemain mieux qu'une règle naïve fondée sur la classe majoritaire. La base contient 1 197 séances du 10 janvier 2022 au 5 novembre 2026. Neuf variables explicatives (rendements retardés, écarts aux moyennes mobiles, volatilités glissantes) sont construites sans fuite d'information, puis trois approches sont comparées avec un découpage strictement chronologique 80 %/20 % : une baseline, une régression logistique et une forêt aléatoire. Sur les 238 jours de test, la baseline atteint une exactitude de 58,8 %, la régression logistique 56,3 % et la forêt aléatoire 60,5 %. L'écart entre la forêt aléatoire et la baseline n'est pas statistiquement significatif ($p = 0{,}32$). Sa balanced accuracy (0,574) est certes supérieure à 0,5, mais ce signal faible provient d'une seule période de test, d'un réglage d'hyperparamètres et de la comparaison de plusieurs modèles : il ne suffit pas pour conclure que le marché est battu. Une simulation de trading avec coûts de transaction montre en outre que tout avantage est très sensible aux frais. Les résultats sont donc compatibles avec l'hypothèse d'efficience faible, sans la démontrer.

Table des matières

1 Introduction générale **3**

2 Présentation de la base de données **3**
2.1 Source et structure 3
2.2 Contrôle de qualité 3
2.3 Statistiques descriptives 4

3 Méthodologie **4**
3.1 Rendements et variable cible 4
3.2 Variables explicatives 5
3.3 Découpage chronologique 5
3.4 Métriques d'évaluation 5
3.5 Tests statistiques indicatifs 5
3.6 Simulation financière 6

4 Analyse exploratoire et visualisations **6**

5 Présentation des modèles de Machine Learning **9**
5.1 Modèle 1 : baseline (classe majoritaire) 9
5.2 Modèle 2 : régression logistique 9
5.3 Modèle 3 : forêt aléatoire 10

6 Résultats et comparaison des performances **11**
6.1 Capacité de prédiction 11
6.2 Simulation financière 12

7 Discussion et limites **13**

8 Conclusion générale **14**

1 Introduction générale

Selon l'hypothèse d'efficience des marchés sous sa forme faible [1], les prix passés incorporent d'ores et déjà l'information contenue dans l'historique des cours : les rendements successifs seraient alors imprévisibles et le cours suivrait une *marche aléatoire*. Si cette hypothèse est vraie, aucun modèle fondé sur les prix passés ne devrait prédire durablement le sens des variations futures mieux qu'une règle simple.

L'action Attijariwafa Bank est l'une des valeurs les plus importantes de la Bourse de Casablanca. Elle constitue un terrain d'étude intéressant, car sa liquidité est réelle mais son marché reste plus étroit que celui des grandes places internationales.

La problématique est la suivante :

> *Les modèles de Machine Learning peuvent-ils prédire la hausse ou la baisse de l'action Attijariwafa Bank avec une précision supérieure à une prédiction de référence fondée sur la classe majoritaire ?*

Le rapport suit cinq étapes : présentation et contrôle de la base de données, construction des variables, analyse exploratoire, comparaison de trois modèles sur une période de test postérieure à l'entraînement, puis évaluation d'une stratégie simulée. Un soin particulier est apporté à l'honnêteté des conclusions : une exactitude supérieure à 50 % n'est pas, en soi, une preuve de capacité prédictive.

2 Présentation de la base de données

2.1 Source et structure

Le fichier `Attijariwafa_Bank_Stock_Price_History.csv` contient l'historique quotidien de l'action ATW, au format de la page « Historical Data » d'Investing.com [2]. Il comporte **1 197 observations** et **7 variables**, dont les types d'origine sont présentés dans le tableau 1. Les dates sont fournies au format américain MM/JJ/AAAA et les observations arrivent dans l'ordre antichronologique : un tri croissant a donc été appliqué.

Table 1 – Variables de la base de données

Variable	Type d'origine	Type après conversion	Description
Date	texte	datetime	Date de la séance
Price	numérique	float	Cours de clôture (MAD)
Open	numérique	float	Cours d'ouverture
High	numérique	float	Plus haut de la séance
Low	numérique	float	Plus bas de la séance
Vol.	texte (ex. « 34.19K »)	float (titres)	Volume échangé
Change %	texte (ex. « 3.67% »)	float (%)	Variation quotidienne

2.2 Contrôle de qualité

La période couverte s'étend du **10 janvier 2022 au 5 novembre 2026**. Les contrôles réalisés sont les suivants :

— aucune valeur manquante et aucun doublon (lignes ou dates) ;

— le volume, exprimé avec les suffixes K (milliers) et M (millions), a été converti en nombre de titres ; 1 196 valeurs sont en K et une seule en M ;
— la variable « Change % » a été comparée au rendement recalculé à partir des cours de clôture : l'écart maximal est de 0,005 point de pourcentage (arrondi) ;
— une seule séance (17 septembre 2026) présente un cours de clôture (713,0) situé hors de l'intervalle [Low, High] (695,0 – 700,0), alors que sa variation de +2,19 % est cohérente avec la séance précédente. Les cours de clôture étant ceux utilisés dans l'étude, cette ligne a été conservée et signalée ;
— les écarts entre deux séances sont de 1 à 6 jours calendaires (week-ends et jours fériés).

2.3 Statistiques descriptives

Le tableau 2 résume les principales variables. Le cours de clôture moyen est d'environ 553,3 MAD ; il est passé de 491,0 MAD (première séance) à 694,6 MAD (dernière séance), avec un minimum de 355,05 MAD (30 janvier 2023) et un maximum de 789,9 MAD (22 août 2025). Le rendement quotidien moyen est de 0,036 % pour un écart-type de 1,21 %. Sa distribution présente un excès de kurtosis de 3,85, signe de queues épaisses (variations extrêmes plus fréquentes que sous une loi normale), et une asymétrie légère (0,19). Sur les 1 196 rendements calculables, 45,6 % sont positifs, 44,8 % négatifs et 9,6 % exactement nuls.

Table 2 – Statistiques descriptives (1 197 observations)

Variable	Moyenne	Écart-type	Min	Médiane	Max
Price (MAD)	553,29	124,51	355,05	512,00	789,90
Open (MAD)	552,53	124,47	360,00	510,00	790,00
High (MAD)	557,23	125,87	360,00	514,90	804,00
Low (MAD)	549,18	123,36	355,05	508,30	781,00
Volume (titres)	50 956	80 835	10	29 300	1 430 000
Variation (%)	0,04	1,21	−5,17	0,00	5,99

3 Méthodologie

3.1 Rendements et variable cible

Le rendement quotidien est calculé à partir du cours de clôture P_t :

$$r_t = \frac{P_t - P_{t-1}}{P_{t-1}}. \tag{1}$$

La variable cible, définie pour une prédiction faite à la clôture de la séance t, est :

$$y_t = \begin{cases} 1 & \text{si } r_{t+1} > 0 \text{ (hausse)}, \\ 0 & \text{sinon (baisse ou stabilité)}. \end{cases} \tag{2}$$

Les 113 jours de rendement strictement nul sont donc classés en « 0 ». Après construction, la part de jours de hausse est de 45,7 % sur l'ensemble des observations exploitables, ce qui signifie que la classe majoritaire globale est la « non-hausse ».

3.2 Variables explicatives

Toutes les variables sont calculées à partir d'informations disponibles à la clôture de t :

— rendement du jour r_t et rendements retardés r_{t-1}, r_{t-2}, r_{t-3}, r_{t-5} ;

— écarts relatifs aux moyennes mobiles de 5 et 10 jours : $\text{MA5_ratio}_t = P_t/\text{MM}_5(t) - 1$ et $\text{MA10_ratio}_t = P_t/\text{MM}_{10}(t) - 1$, où $\text{MM}_k(t) = \frac{1}{k}\sum_{i=0}^{k-1} P_{t-i}$. Exprimer la moyenne mobile en écart relatif plutôt que en niveau évite d'introduire une variable non stationnaire ;

— volatilités glissantes sur 5 et 10 jours : écart-type des rendements sur la fenêtre correspondante.

Les 10 premières lignes (retards, fenêtres glissantes) et la dernière (sans lendemain) sont supprimées : **1 186 observations** sont conservées.

3.3 Découpage chronologique

Les 1 186 observations sont triées dans l'ordre du temps. Les 80 % les plus anciennes servent à l'entraînement et les 20 % les plus récentes au test (tableau 3). La dernière ligne de la période d'entraînement est retirée, car sa cible (le rendement du lendemain) coïncide avec le premier jour du test. Aucun tirage aléatoire n'est utilisé. La standardisation $z = (x - \mu_{\text{train}})/\sigma_{\text{train}}$ est ajustée uniquement sur l'entraînement (elle est intégrée dans un `Pipeline`), et l'optimisation des hyperparamètres emploie une validation croisée temporelle (`TimeSeriesSplit`, 5 blocs) à l'intérieur de l'entraînement seulement.

Table 3 – Découpage chronologique des données

Jeu	Observations	Début	Fin	Part de hausses
Entraînement	947	25/01/2022	12/11/2025	46,9 %
Test	238	14/11/2025	04/11/2026	41,2 %

Le tableau 3 éclaire déjà un point essentiel : la classe majoritaire de l'entraînement est la non-hausse (53,1 %), et elle l'est encore davantage dans le test (58,8 %). La baseline prédira donc toujours « pas de hausse » et sera difficile à battre en exactitude.

3.4 Métriques d'évaluation

À partir de la matrice de confusion (VP, VN, FP, FN) :

$$\text{Accuracy} = \frac{VP + VN}{VP + VN + FP + FN}, \qquad \text{Precision} = \frac{VP}{VP + FP}, \tag{3}$$

$$\text{Recall} = \frac{VP}{VP + FN}, \qquad F_1 = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}, \tag{4}$$

$$\text{Balanced Acc.} = \frac{1}{2}\left(\frac{VP}{VP + FN} + \frac{VN}{VN + FP}\right). \tag{5}$$

La balanced accuracy est indispensable ici : une baseline qui prédit toujours la même classe obtient une exactitude élevée mais une balanced accuracy d'exactement 0,5.

3.5 Tests statistiques indicatifs

Deux tests sont employés, à titre indicatif :

1. un **test binomial unilatéral** : sous H_0, le nombre de prédictions correctes suit une loi binomiale $\mathcal{B}(n, p_0)$ avec p_0 égal à l'exactitude de la baseline sur le test ; on calcule $P(X \geq k)$;
2. un **test de permutation** sur la balanced accuracy : les étiquettes du test sont mélangées 5 000 fois et l'on mesure la fréquence de balanced accuracy au moins égales à celle observée.

Leurs limites sont discutées en section 7.

3.6 Simulation financière

La stratégie est la suivante : à la clôture de t, si le modèle prédit une hausse, l'investisseur détient l'action pendant la séance $t+1$; sinon il reste en liquidités (rendement nul). Le rendement net de la stratégie est

$$r^{\text{strat}}_{t+1} = s_t \, r_{t+1} - c \, |s_t - s_{t-1}|, \tag{6}$$

où $s_t \in \{0, 1\}$ est la position et $c = 0{,}1\,\%$ le coût par changement de position (hypothèse, avec sensibilité à $0\,\%$ et $0{,}3\,\%$). Il n'y a ni vente à découvert ni levier, l'exécution est supposée au cours de clôture. La stratégie passive « Buy and Hold » achète au début du test (avec le même coût) et conserve. On calcule le rendement cumulé, le ratio de Sharpe annualisé (taux sans risque supposé nul) [4]

$$\text{Sharpe} = \sqrt{252}\,\frac{\bar{r}}{\sigma_r}, \tag{7}$$

et le drawdown maximal $\min_t \left(\frac{V_t}{\max_{u \leq t} V_u} - 1 \right)$, où V_t est la valeur du portefeuille.

4 Analyse exploratoire et visualisations

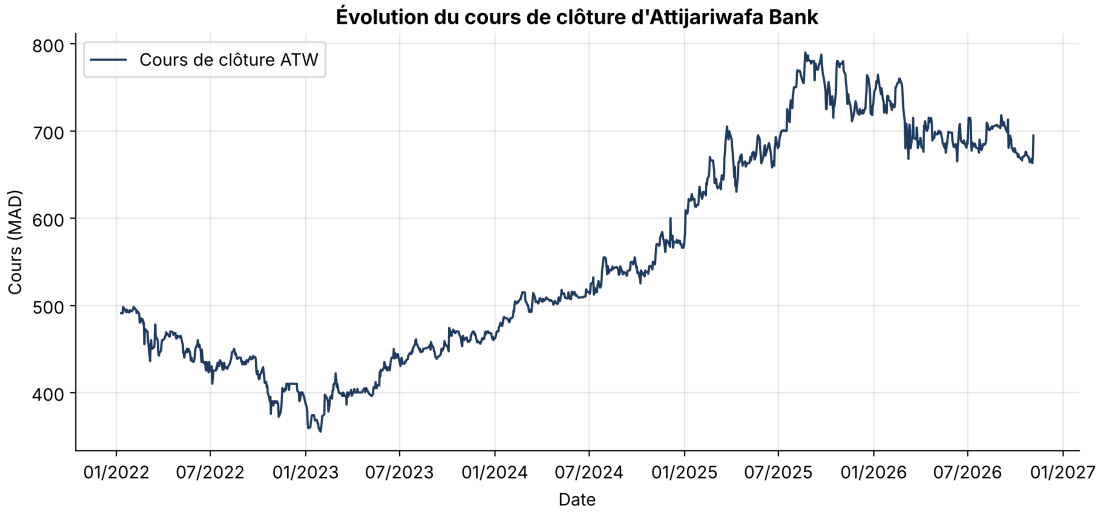


Figure 1 – Évolution du cours de clôture d'ATW.

La figure 1 montre une phase de baisse jusqu'à un point bas de 355,05 MAD en janvier 2023, puis une hausse marquée jusqu'au sommet d'août 2025. Depuis, le cours recule : il passe de 736,0 MAD (14 novembre 2025) à 694,6 MAD (5 novembre 2026). La période de test est donc une phase baissière ou de consolidation, ce qui explique la part élevée de jours sans hausse.

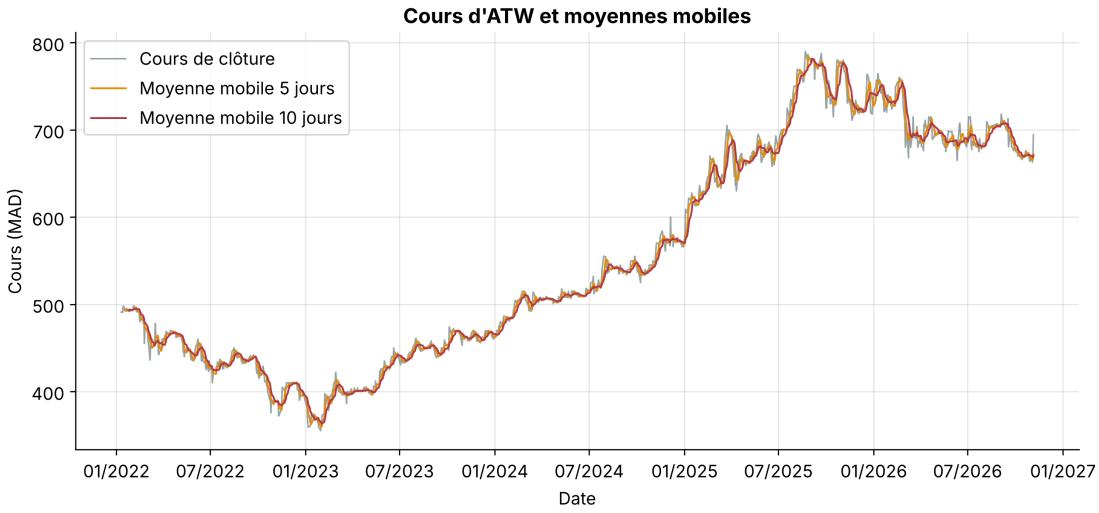


Figure 2 – Cours d'ATW et moyennes mobiles de 5 et 10 jours.

Les moyennes mobiles (figure 2) lissent le cours et suivent la tendance avec retard ; leur écart au cours fournit aux modèles une mesure de momentum de court terme.

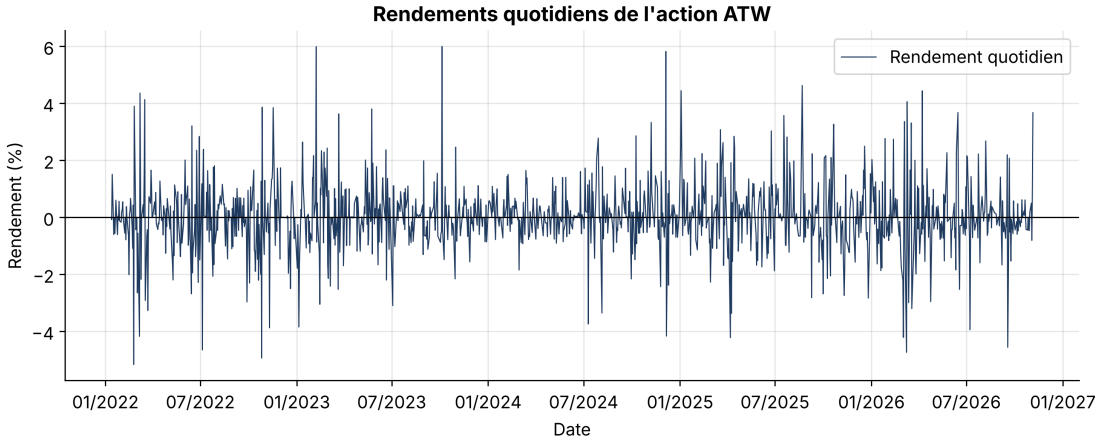


Figure 3 – Rendements quotidiens de l'action ATW.

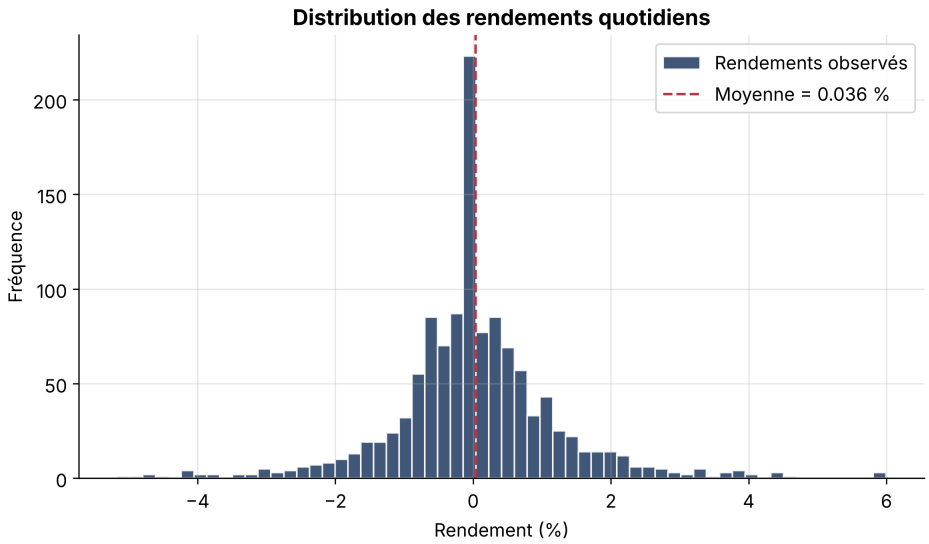


Figure 4 – Distribution des rendements quotidiens.

Les rendements (figures 3 et 4) oscillent autour de zéro, avec une volatilité qui varie dans le temps (périodes plus agitées suivies de périodes calmes). La forte concentration de valeurs au centre, liée aux 9,6 % de rendements nuls (cours inchangé), et les queues épaisses (kurtosis excessive de 3,85) montrent que la loi normale est une mauvaise approximation.

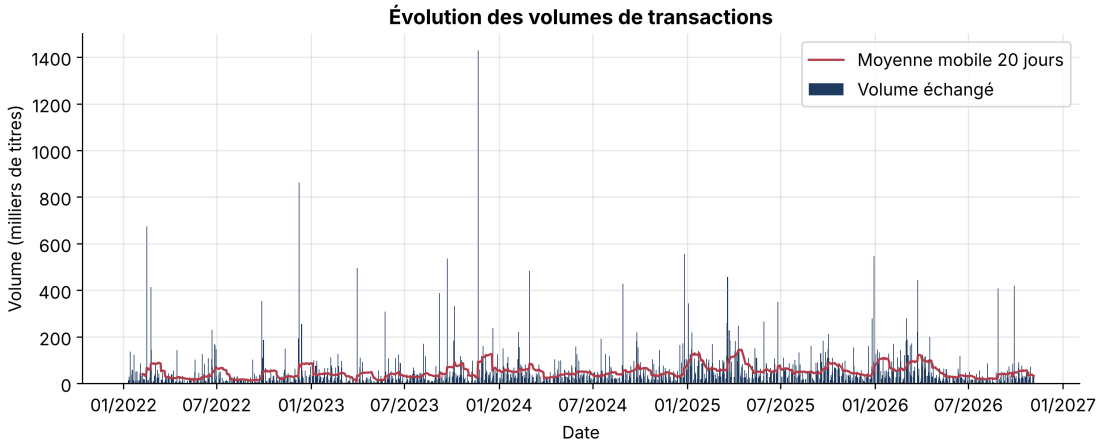


Figure 5 – Évolution des volumes de transactions.

Les volumes (figure 5) sont très irréguliers : médiane de 29 300 titres, mais un pic à 1,43 million de titres. Cette variable n'est pas utilisée comme explicative dans le modèle principal.

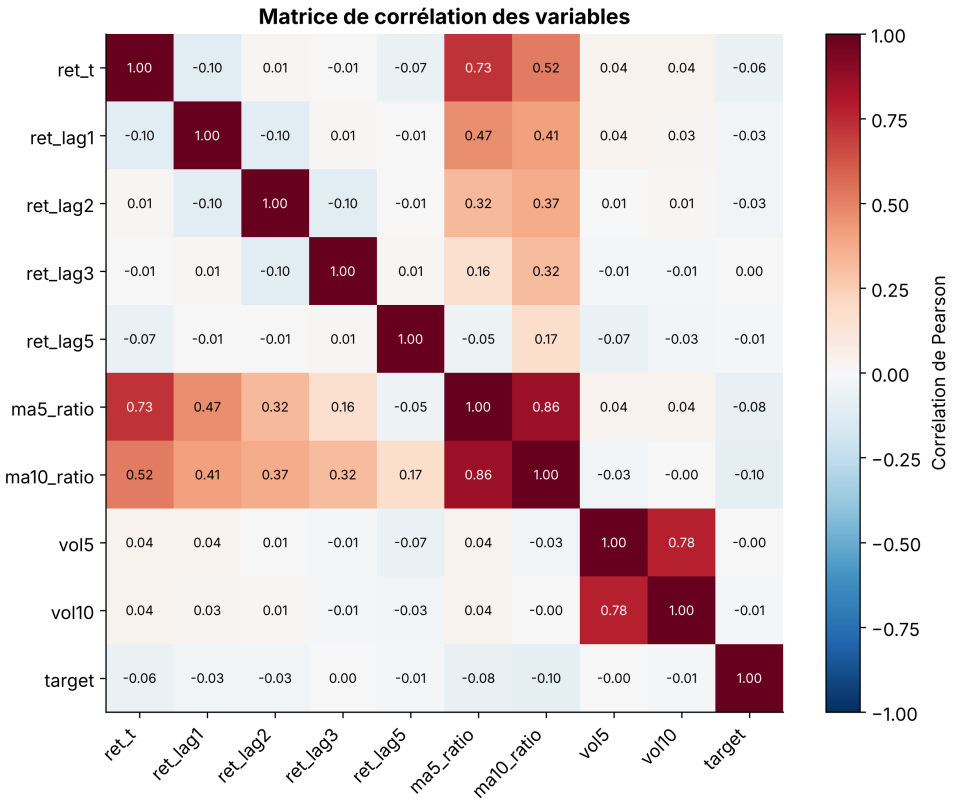


Figure 6 – Matrice de corrélation des variables explicatives et de la cible.

La matrice de corrélation (figure 6) montre que les variables liées (écarts aux moyennes mobiles, rendement du jour, volatilités de fenêtres voisines) sont corrélées entre elles, ce qui est attendu puisqu'elles partagent des observations. En revanche, les corrélations avec la cible sont faibles : aucune variable ne sépare nettement les jours de hausse des autres. C'est un premier indice de la difficulté de la prédiction.

5 Présentation des modèles de Machine Learning

5.1 Modèle 1 : baseline (classe majoritaire)

Le modèle prédit systématiquement la classe la plus fréquente de l'entraînement, ici la non-hausse. Il ne tire aucune information des variables : il fixe le niveau minimal que tout modèle doit dépasser pour justifier sa complexité.

5.2 Modèle 2 : régression logistique

Le modèle estime la probabilité de hausse par

$$P(y_t = 1 \mid \mathbf{x}_t) = \frac{1}{1 + \exp\big(-(\beta_0 + \boldsymbol{\beta}^\top \mathbf{z}_t)\big)}, \tag{8}$$

où $\mathbf{z}_t$ sont les variables standardisées. Une hausse est prédite si cette probabilité dépasse 0,5. Le paramètre de régularisation C est choisi parmi $\{0{,}01;\ 0{,}1;\ 1;\ 10\}$ par validation croisée temporelle (critère : balanced accuracy) ; la valeur retenue est $C = 10$.

Le tableau 4 donne les coefficients. Le coefficient le plus marqué est celui de MA10_ratio ($-0{,}43$) : un cours situé nettement au-dessus de sa moyenne de 10 jours est associé à une probabilité de hausse plus faible le lendemain, ce qui est la signature d'un effet de retour à la moyenne de court terme. Les autres coefficients sont petits. Ces coefficients décrivent le modèle ajusté sur l'entraînement ; on ne leur a pas associé de test de significativité, et ils ne prouvent pas une relation exploitable.

Table 4 – Coefficients de la régression logistique (variables standardisées)

Variable	Coefficient
MA10_ratio	$-0{,}429$
vol5	$-0{,}044$
ret_t (r_t)	0,013
vol10	0,017
ret_lag5	0,065
ret_lag1	0,076
ret_lag3	0,117
ret_lag2	0,122
MA5_ratio	0,127

5.3 Modèle 3 : forêt aléatoire

Une forêt aléatoire [3] agrège 300 arbres de décision entraînés sur des échantillons bootstrap et des sous-ensembles de variables ; la prédiction est le vote majoritaire. Une grille réduite (profondeur maximale $\in \{3, 5, 8\}$, taille minimale de feuille $\in \{10, 20, 40\}$) est parcourue par validation croisée temporelle sur l'entraînement, avec la balanced accuracy comme critère. La combinaison retenue est une profondeur de 5 et 20 observations minimum par feuille. Le score de validation obtenu est de 0,518 pour la forêt et 0,507 pour la régression logistique : dès l'entraînement, ces scores sont proches de 0,5.

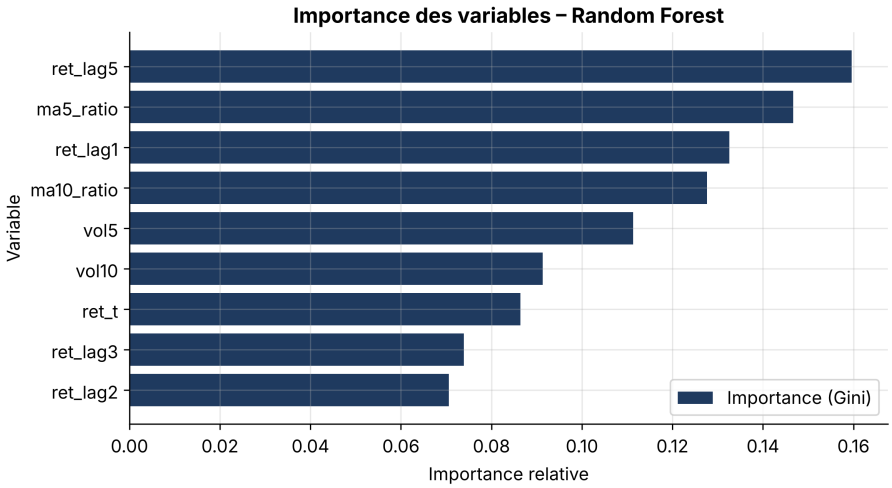


Figure 7 – Importance des variables dans la forêt aléatoire.

La figure 7 montre une importance répartie assez uniformément (de 0,07 à 0,16), sans variable dominante. Ces importances décrivent le fonctionnement interne du modèle et ne mesurent pas une capacité de prédiction.

6 Résultats et comparaison des performances

6.1 Capacité de prédiction

Le tableau 5 présente les performances sur les 238 jours de test (du 14/11/2025 au 04/11/2026).

Table 5 – Performances sur le jeu de test (238 jours)

Modèle	Accuracy	Precision	Recall	F1	Balanced Acc.
Baseline (majoritaire)	0,588	0,000	0,000	0,000	0,500
Régression logistique	0,563	0,463	0,378	0,416	0,535
Random Forest	0,605	0,527	0,398	0,454	0,574

Table 6 – Tests statistiques indicatifs

Modèle	% hausses prédites	p binomial vs baseline	p permutation (BA)
Régression logistique	33,6 %	0,804	0,162
Random Forest	31,1 %	0,324	0,009

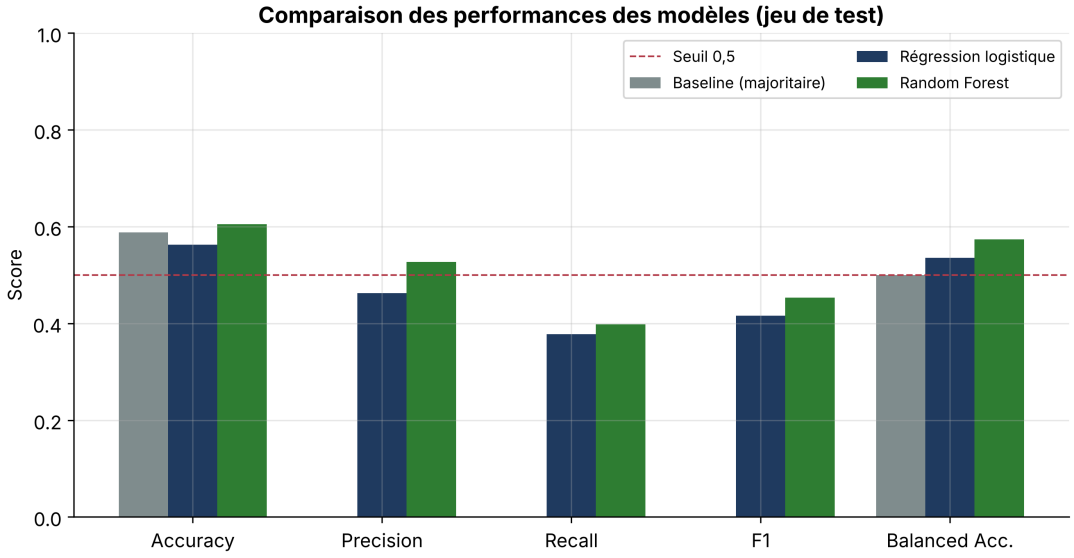


Figure 8 – Comparaison des performances des modèles sur le jeu de test.

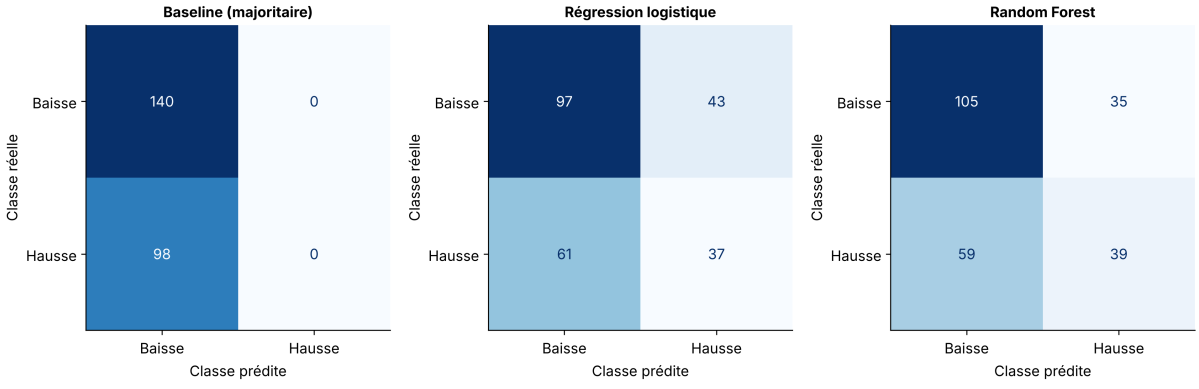


Figure 9 – Matrices de confusion sur le jeu de test.

Interprétation. La baseline prédit toujours la non-hausse et obtient 58,8 % d'exactitude (140 jours sur 238), mais elle ne détecte aucune hausse (recall nul) : sa balanced accuracy est de 0,5, valeur de référence d'un prédicteur sans information. La régression logistique (56,3 %) reste sous la baseline en exactitude ; la forêt aléatoire (60,5 %, soit 144 prédictions correctes) la dépasse de 1,7 point, mais l'écart n'est pas significatif ($p = 0{,}32$, soit 4 prédictions correctes de plus que la baseline : une différence que le hasard produit facilement sur 238 jours). Le test de permutation donne pour la forêt une p-valeur de 0,009 sur la balanced accuracy, ce qui indique que la répartition de ses bonnes prédictions entre hausses et baisses est difficilement explicable par un simple mélange des étiquettes. Ce résultat est le seul élément plutôt favorable de l'étude. Pour la régression logistique ($p = 0{,}16$), aucune capacité de prédiction n'est mise en évidence.

Il faut toutefois relativiser fortement ce résultat (voir section 7) : la p-valeur de 0,009 n'est pas corrigée des comparaisons multiples (deux modèles, plusieurs combinaisons d'hyperparamètres, deux tests), repose sur une seule période d'une année, et le test de permutation suppose des jours indépendants, ce qui est une approximation pour une série financière. Par ailleurs, la précision de la forêt sur les hausses reste modeste : sa precision (0,527) signifie qu'une prédiction de hausse sur deux environ est juste, et son recall (0,398) qu'elle détecte moins de 40 % des hausses réelles.

6.2 Simulation financière

Le tableau 7 donne les résultats de la stratégie avec un coût de 0,1 % par changement de position et le tableau 8 la sensibilité du Sharpe aux frais.

Table 7 – Performance des stratégies simulées sur le test (coût de 0,1 %)

Stratégie	Changements	Rend. cumulé	Sharpe	Drawdown max
Baseline (toujours en liquidités)	0	0,0 %	non défini	0,0 %
Régression logistique	88	−5,7 %	−0,42	−12,3 %
Random Forest	86	+6,1 %	0,61	−8,4 %
Buy and Hold	1	−5,7 %	−0,20	−13,3 %

Table 8 – Ratio de Sharpe annualisé selon le coût de transaction

Stratégie	0 %	0,1 %	0,3 %
Régression logistique	0,31	−0,42	−1,85
Random Forest	1,41	0,61	−0,98
Buy and Hold	−0,20	−0,20	−0,21

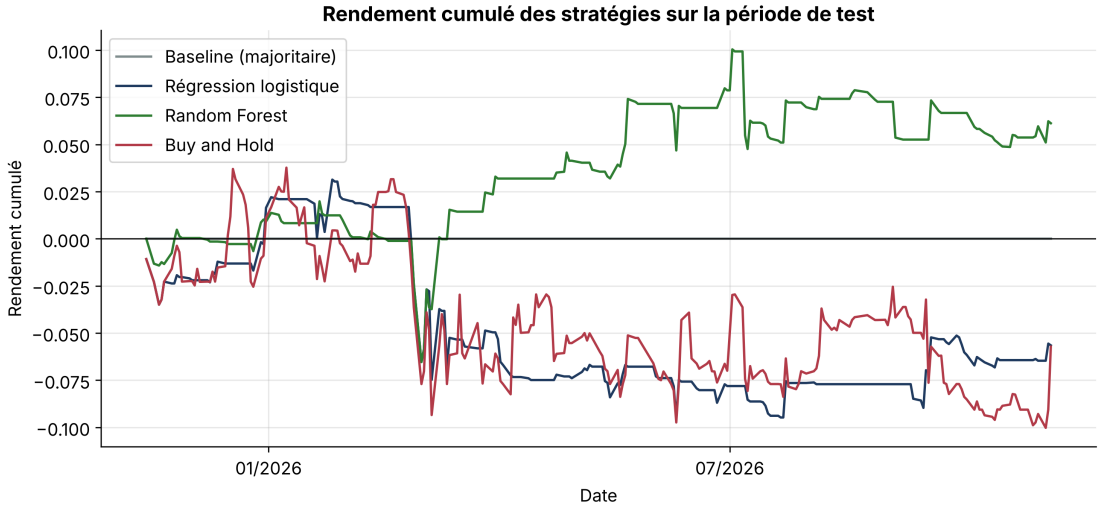


Figure 10 – Rendement cumulé des stratégies sur la période de test (coût de 0,1 %).

La baseline ne prend jamais de position : son rendement est nul et son Sharpe non défini. Le Buy and Hold perd 5,7 % sur la période, ce qui reflète la phase baissière. La stratégie fondée sur la forêt aléatoire obtient +6,1 % et un Sharpe de 0,61, mais ce résultat est très fragile : il est obtenu avec 86 changements de position sur 238 jours, il disparaît (Sharpe de −0,98) avec un coût de 0,3 %, et il vient d'une seule trajectoire de prix. La régression logistique perd autant que le marché à 0,1 %. Notons que dans cette période, ne pas être investi est déjà une bonne décision, et que la stratégie du modèle bénéficie en partie de sa propension à rester hors du marché (elle prédit une hausse seulement un jour sur trois). Un Sharpe positif sur une seule année, sans interval de confiance, n'est pas une preuve de rentabilité.

7 Discussion et limites

Ce que montrent les résultats. La baseline est la référence à battre et, en exactitude, aucun modèle ne la bat de façon significative. La forêt aléatoire présente une balanced accuracy de 0,574 : c'est un signal faible, qui ne contredit pas l'efficience faible de manière décisive, mais qui ne permet pas non plus de la rejeter. Les conclusions précises sont donc : (i) pas de preuve que les modèles battent la classe majoritaire ; (ii) indice limité, non confirmé, d'une information très légère dans les prix récents ; (iii) aucune preuve de rentabilité réaliste.

Performance statistique et performance financière. Ces deux notions diffèrent. Une exactitude plus élevée ne garantit pas un gain : les gains dépendent de l'amplitude des mouvements, pas seulement de leur sens, et chaque changement de position coûte. À l'inverse, la stratégie du Random Forest gagne en partie parce qu'elle se tient souvent hors d'un marché qui baisse, ce qui n'est pas la même chose qu'une meilleure prédiction.

Limites.

— **Taille de la base** : 1 197 séances, soit seulement 238 jours de test. Avec $n = 238$, l'incertitude sur une exactitude est d'environ ±3 points (écart-type $\approx \sqrt{0{,}6 \times 0{,}4/238} = 3{,}2$ points), du même ordre que les écarts observés entre modèles.

— **Une seule période de test**, d'un an, baissière ou stable : les résultats peuvent ne pas se généraliser à d'autres régimes de marché. La proportion de hausses passe de 46,9 % (entraînement) à 41,2 % (test), ce qui montre un décalage de distribution.

— **Comparaisons multiples et *data snooping*** : essayer plusieurs modèles et réglages puis retenir le meilleur gonfle les performances ; la p-valeur de 0,009 n'est pas corrigée. Les hyperparamètres ont été choisis par validation sur l'entraînement seulement, jamais sur le test, ce qui limite mais n'élimine pas ce risque.
— **Hypothèses des tests** : le test binomial traite l'exactitude de la baseline comme une constante connue et suppose les observations indépendantes ; le test de permutation fait de même. Les rendements réels présentent de la volatilité groupée, donc ces p-valeurs sont approximatives.
— **Simulation** : coût de 0,1 % supposé, exécution au cours de clôture (en pratique soumise à l'écart achat–vente, au glissement et à la liquidité), pas d'impôts, taux sans risque nul, une seule trajectoire.
— **Information limitée** : seules les données de prix et de volume de l'action sont utilisées ; ni les résultats de la banque, ni le marché global, ni des variables macroéconomiques n'ont été intégrés.
— **Qualité des données** : une ligne présente un cours de clôture hors de l'intervalle [Low, High] (voir section 2).
— **Efficience des marchés** : le test s'inscrit dans le cadre de l'efficience faible. L'absence de détection n'en prouve pas la validité ; elle indique seulement que cette approche simple, sur ces données, ne révèle pas de prévisibilité exploitable.

Pistes d'amélioration. Allonger l'historique, utiliser une validation par fenêtres glissantes (walk-forward), ajouter des variables externes (indices du marché, taux, volumes), corriger les tests pour les comparaisons multiples et modéliser la volatilité.

8 Conclusion générale

Ce projet étudiait si l'historique de l'action Attijariwafa Bank permet de prédire le sens du rendement du lendemain avec une précision supérieure à une prédiction fondée sur la classe majoritaire. Sur 238 jours de test, la baseline atteint 58,8 %, la régression logistique 56,3 % et la forêt aléatoire 60,5 %. Aucun modèle ne bat significativement la baseline en exactitude, et la régression logistique ne montre aucun signal. La forêt aléatoire présente une balanced accuracy de 0,574 (non nulle), mais ce résultat reste fragile : une seule période, des tests non corrigés et une taille d'échantillon limitée. En simulation, un avantage apparaît pour la forêt avec des frais de 0,1 % (Sharpe de 0,61 contre $-0{,}20$ pour le Buy and Hold) mais s'inverse avec des frais de 0,3 %.

La conclusion académique est donc nuancée : les résultats sont compatibles avec l'hypothèse d'efficience faible et ne démontrent pas que le marché puisse être battu avec des modèles simples fondés sur les prix passés. Un signal faible ne peut pas être exclu, mais il faudrait le confirmer sur davantage de données et de périodes avant toute exploitation. Au-delà du résultat, ce travail illustre la rigueur nécessaire en finance quantitative : découpage chronologique, absence de fuite d'information, comparaison à une référence naïve, prise en compte des coûts et prudence dans l'interprétation.

Références

[1] E. F. Fama, « Efficient Capital Markets : A Review of Theory and Empirical Work », *The Journal of Finance*, 25(2), 383–417, 1970.

[2] Investing.com, *Attijariwafa Bank – Historical Data*, https://www.investing.com, données téléchargées en novembre 2026.

[3] L. Breiman, « Random Forests », *Machine Learning*, 45(1), 5–32, 2001.

[4] W. F. Sharpe, « The Sharpe Ratio », *The Journal of Portfolio Management*, 21(1), 49–58, 1994.

[5] T. Hastie, R. Tibshirani et J. Friedman, *The Elements of Statistical Learning*, 2e éd., Springer, 2009.

[6] F. Pedregosa et al., « Scikit-learn : Machine Learning in Python », *Journal of Machine Learning Research*, 12, 2825–2830, 2011.

[7] W. McKinney, « Data Structures for Statistical Computing in Python », *Proceedings of the 9th Python in Science Conference*, 56–61, 2010.

[8] C. R. Harris et al., « Array programming with NumPy », *Nature*, 585, 357–362, 2020.

[9] P. Virtanen et al., « SciPy 1.0 : Fundamental Algorithms for Scientific Computing in Python », *Nature Methods*, 17, 261–272, 2020.

[10] J. D. Hunter, « Matplotlib : A 2D Graphics Environment », *Computing in Science & Engineering*, 9(3), 90–95, 2007.

[11] A. W. Lo et A. C. MacKinlay, « Stock Market Prices Do Not Follow Random Walks », *The Review of Financial Studies*, 1(1), 41–66, 1988.